ANALISI DI DATI SU LARGA SCALA

Prof. Dario Malchioni
6 CFU

Luca Cappelletti

Lecture Notes
Year 2017/2018

Magistrale Informatica
Università di Milano
Italy
October 10, 2017

Contents

Chapter 1

Chapter 2

1.1 Analisi di complessità di un job map-reduce

1.1.1 Es: moltiplicazione di matrici

$$A_{m\times n}\times B_{m\times o}(i,j,a_{ij})\longmapsto M_A((i,j),(A,k,a_{ik}))\forall\, j=1,...,o(k,j,b_{kj})\longmapsto M_B((i,j),(B,k,b_{ik}))\forall\, i=1,...,m(i,j)[(A,1,a_{i1}),...,(A,m,a_{im})$$

$$R(A,B)\bowtie S(B,C)\bowtie T(C,D)(a,b)\longmapsto_{M_R}(b,(R,a))(b,c)\longmapsto_{M_S}(b,(S,a))$$

Quale è il costo di questo algoritmo. Indichiamo con r,s,t i rispettivi numeri di tuple delle tabelle R, S, T. Il primo processo M_R riceve tutte e sole le tuple di R, quindi ha costo r. Il secondo, similmente, ha costo s.

Il risultato del costo di complessità sarà quindi un $O(r+s)$. Ma questo è tra due relazioni. Se volessi farlo da 3 relazioni (**join in cascata**) cosa andrei ad ottenere?

$(R\bowtie S)\bowtie T$

Ottengo il costo $O(r+s+t+rsp)$, con p rappresentante la probabilità che due valori di R e S hanno un attributo uguale.

1.1.2 Join multi-way

Date due funzioni di hash, una h per l'attributo B ed una g per l'attributo C, con b **bucket** e c **bucket**, avendo che $bc=k$.
Nel caso di una tupla $(u,v)\in R$ viene inviata ad un'unica colonna verticale, riducendo i nodi (**c reducer**).
Nel caso di una tupla $(w,z)\in T$ viene inviata ad un'unica colonna orizzontale, riducendo i nodi (**b reducer**).
Nel caso di una tupla $(v,w)\in S$ viene inviata ad un'unica cella, riducendo i nodi ad uno soltanto (**1 reducer**).
Il costo quindi risulta essere:

$$O(r+2s+t+cr+bt)$$

1.1.3 Rilassamento lagrangiano

N.B. Il parametro lambda non può essere negativo.

$$L(b,c)=cr+br-\lambda(bc-k)$$

$$\frac{dL(b,c)}{db}=0$$

$$\frac{dL(b,c)}{dc} = 0$$

Ottengo quindi un sistema:

$$\begin{cases} t - \lambda c = 0 \\ r - \lambda b = 0 \end{cases} \Longrightarrow \begin{cases} t = \lambda c \\ r = \lambda b \end{cases}$$

$$\lambda = \sqrt{\frac{rt}{k}}$$

$$c = \sqrt{\frac{kt}{r}}$$

$$b = \sqrt{\frac{kr}{t}}$$

Il **costo ottimizzato** della **join multiway** risulta quindi essere:

$$O(r + 2s + t + 2\sqrt{krt})$$

1.1.4 Es: Join sui nodi di facebook

Prendiamo ad esempio il grafo dei nodi facebook, dotato di 10^9 nodi.

$R(U_1, U_2)$, $|R| = r = 3 \times 10^1 1$ (dati arbitrari)

$$R \bowtie R \bowtie R$$

Approccio Multi-way: $r + 2r + r + 2r\sqrt{k} = 4r + 2r\sqrt{k} = 1 \times 2 \times 10^1 2 + 6 \times 10^1 1\sqrt{k}$
Approccio cascata (nell'ipotesi che $absR \bowtie R = 30r$): $r + r + r + r^2 \times p = ... = 2r + 60r = 1 \times 2 \times 10^1 2 + 1 \times 86 \times 10^1 3$

Ottengo quindi che: $6 \times 10^1 1\sqrt{k} \leq 1 \times 86 \times 10^3 3 \longrightarrow k \leq 961$, e risulta quindi migliore utilizzare l'approccio multi way quando si hanno meno di 961 nodi da allocare a dei reducer.

1.1.5 Es: Google pagerank

Come funziona **pagerank**:

	A	B	C	D
A	0	1/2	1	0
B	1/3	0	0	1/2
C	1/3	0	0	1/2
D	1/3	1/2	0	0

$v_j(t+1) = P$(Trovarsi in j al tempo t+1) $= \sum_i P$(trovarsi in i al tempo t) • P(spostarsi da i a j | trovarsi in i al punto t)

$$\sum_i v_i(t) m_{ji} = \sum_i m_{ji} v_i(t) = (Mv(t))_j$$

con $M_{ij} = P$Spostarsi da j a i.

$$\vec{V}(t+1) = M\vec{v}(t)$$

Prova di convergenza

Definizione 1.1.1 (Determinante)

$$detA = \sum_i a_{ij} c_{ij} = \sum_j a_{ij} c_{ij}$$

Definizione 1.1.2 (Determinante di matrice trasposta) *Una matrice e la sua trasposta possiedono lo stesso determinante.*

$$detA^T = \sum_i a_{ij}^T c_{ij}^T = \sum_i a_{ji} c_{ji} = \sum_j a_{ij} c_{ij}$$

Definizione 1.1.3 (Autovalori) *Si ottengono trovando gli zeri dell'equazione caratteristica.*

$$det(A - \lambda I) = 0 \leftrightarrow det(A - \lambda I)^T = 0 \leftrightarrow (A^T - \lambda I) = 0$$

Definizione 1.1.4 (Matrice stocastica per righe) *Una qualsiasi matrice stocastica per righe ammette* 1 *come autovettore.*

$$\forall i \sum_j a_{ij} = 1$$

Definizione 1.1.5 (Matrice stocastica per colonne) *Una qualsiasi matrice stocastica per colonne ammette* 1 *come autovettore poiché si tratta della trasposta di una matrice stocastica per righe.*

Teorema 1.1.6 (La potenza di una matrice stocastica è sempre stocastica) *Il risultato dell'elevazione a potenza di una matrice stocastica risulta sempre essere stocastico. Dimostriamo per induzione:*

$$\textit{Base: } k = 1 \qquad A^k = A$$

$$\textit{Passo: } A^k \textit{ stocastica} \rightarrow A^{k+1} \textit{ stocastica}$$

Dimostriamo che ad un generico passo k, otteniamo sempre 1 quando andiamo a sommare i termini.

$$a_{ij}^{k+1} = \sum_s a_{ij}^k a_{sj} \sum_j a_{ij}^k = \sum_j \sum_s a_{is}^k a_{sj}$$

Inverto le sommatorie ed ottengo:

$$\sum_s a_{is}^k \sum_j a_{sj} = \sum_s a_{is}^k = 1$$

Teorema 1.1.7 (Autovalori di una stocastica) *Se A è stocastica per colonne, il suo autovalore massimo è 1.*

Procediamo a dimostrare per assurdo.

Sappiamo che 1 è un autovale di A, poiché A è stocastica. Affermiamo che, per assurdo, esista un $\lambda > 1$ *autovalore di A (che è anche l'autovalore di* A^T*) e* v *un autovettore per* λ*.*

$$A^T v \Rightarrow \lambda v$$

$$A^{2T} v = A^T \times A^T v = A(\lambda v) = \lambda A^T v = \lambda^2 v \Rightarrow A^{Tk} v = \lambda^k v$$

Maggioriamo / minoriamo la sommatoria:

$$\sum_j a_{ij}^{Tk} v_{max} \geq \sum_j a_{ij}^{Tk} v_j = \lambda^k v_i > G$$

$$v_{max} \sum_j a_{ij}^{Tk} > G$$

Ma siccome la sommatoria è dei termini di una matrice stocastica per righe (essendo la trasposta di A), deve essere pari a 1, per cui:

$$v_{max} \sum_j a_{ij}^{Tk} = v_{max} > G$$

$$1 > \frac{G}{v_{max}} \Rightarrow \textit{assurdo!}$$

Teorema 1.1.8 (Autovalori di potenza di matrice)

$$v_0 \to v_1 = Av_0 \to v_2 = Av_1 = A^2 v_0 \to ... \to v_k = A^k v_0$$

Dimostrazione

$$Av_0 = A(\alpha_1 x_1 + \alpha_2 x_2 + ... + \alpha_n x_n) \qquad = \alpha_1 Ax_1 + \alpha_2 Ax_2 + ... + \alpha_n Ax_n = \alpha_1 \lambda_1 x_1 + \alpha_2 \lambda_2 x_2 + ... + \alpha_n \lambda_n x_n$$

$$v_k = A^k v_0 = \alpha_1 \lambda_1^k x_1 + \alpha_2 x_2 \frac{\lambda_2^k \lambda_1^k}{\lambda_1^k} + ... + \alpha_k x_k \frac{\lambda_k^k \lambda_1^k}{\lambda_1^k}$$

$$v_k = A^k v_0 = \lambda_1^k (\alpha_1 x_1 + \alpha_2 x_2 \frac{\lambda_2^k}{\lambda_1^k} + ... + \alpha_k x_k \frac{\lambda_k^k}{\lambda_1^k})$$

per k "grande" $v_k = A^k v_0 \approx \lambda_1^k \alpha_1 x_1$, *nel nostro caso* $\lambda_1 = 1$, *cioè* $\lim_{k\to\infty} \alpha_1 \lambda_1^k x_1 = 1$.

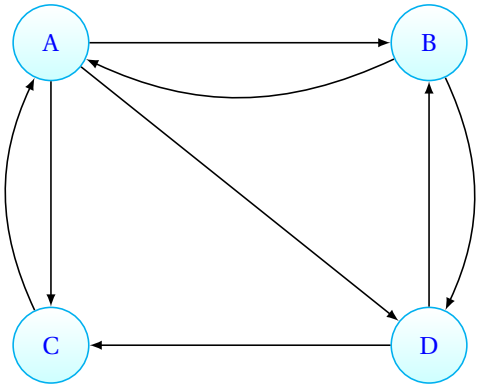

Figure 1.1: In questo grafo, dopo 10 esecuzioni, pagerank assegna assegna ai nodi A, B, C, D rispettivamente $^3/_9, ^2/_9, ^2/_9 e ^2/_9$.

1.1.6 Trappole per ragni

Nodi di grafi (figura 1.2) con loop, da cui gli spider non possono uscire.

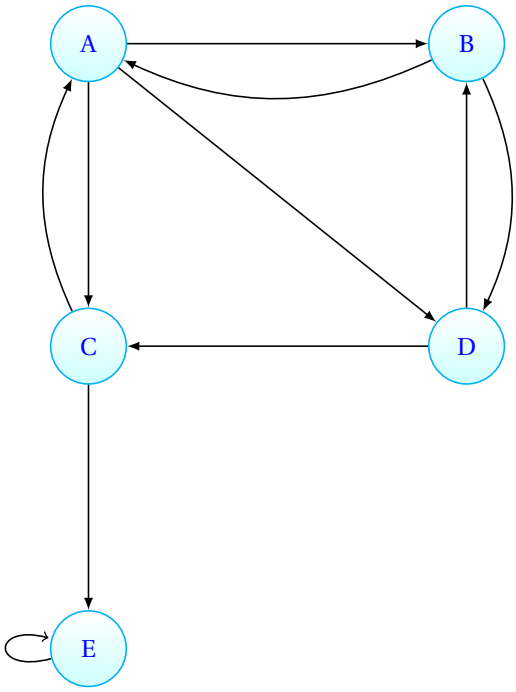

Figure 1.2: Dopo un certo numero di iterazioni, tutta la "massa" distribuita inizialmente sul grafo sarà finita su E

.

1.1.7 Risolvere le trappole per ragni col teletrasporto

Per evitare le trappole per ragni, andiamo a inserire una certa probabilità β di teletrasportarci da un nodo ad un altro al posto di continuare a navigare tramite link.

$$\boldsymbol{v}_{t+1} = \beta M \boldsymbol{v}_t + (1-\beta)\frac{1}{n}\mathbf{1}$$

P(mi trovo in i al tempo $t+1$) = P(spostarsi tramite link in i | scelgo i link) P(scelgo i link) + P (teletrasportarsi in i | mi teletrasporto) P(scegliere teletrasporto)